Klasifikacija melanoma na osnovu dermoskopskih snimaka

Miloš Bojanić

Katedra za informatiku

Fakultet tehničkih nauka, Novi Sad

bojanic.r223.2025@uns.ac.rs

Jelena Adamović

Katedra za informatiku

Fakultet tehničkih nauka, Novi Sad

adamovic.r212.2025@uns.ac.rs

Apstrakt - Melanom je najagresivniji oblik raka kože i vodeći uzrok smrti povezanih sa kožnim karcinomima, njegovo rano otkrivanje značajno povećava stopu preživljavanja. U ovom radu predstavljen je sistem za binarnu klasifikaciju melanoma iz dermoskopskih snimaka zasnovan na dubokim neuronskim mrežama, koji je evaluiran na *ISIC 2020* skupu (33.126 slika, 1,76% malignih). Poređene su dve arhitekture:

(1) *baseline Custom CNN*,
(2) *EfficientNet B0*,

sve uz kasnu fuziju vizuelnih obeležja sa demografskim metapodacima i *Hu* momentima oblika. Za rešavanje ekstremnog disbalansa klasa primenjeni su *Focal Loss* i *StratifiedGroupKFold* podela po pacijentima kako bi se sprečilo curenje podataka. Pored standardnih metrika (*AUC-ROC, Preciznost, Odziv, F1, Macro F1*), sprovedena je analiza pravičnosti (eng. *Equalized Odds*) po polu i starosnim grupama, kao i kvalitativna analiza grešaka. *EfficientNet B0* postiže najbolji rezultat sa *AUC-ROC* (*eng. Area Under the ROC Curve*) *od 0,885*, što predstavlja poboljšanje od 6,4% u odnosu na *baseline CNN* (0,821). Rezultati potvrđuju vrednost transfer learning pristupa za male medicinske skupove podataka, a analiza pravičnosti ukazuje na umerene razlike između starosnih grupa, što otvara prostor za buduća istraživanja.

Ključne reči - klasifikacija melanoma, duboko učenje, konvolutivne neuronske mreže, transfer learning

I. Uvod

Melanom je najagresivniji oblik raka kože - čini manje od 5% svih slučajeva karcinoma kože, ali je odgovoran za preko 75% smrtnih ishoda povezanih sa ovom grupom bolesti [1]. Ključni faktor za uspešno lečenje je rano otkrivanje, petogodišnja stopa preživljavanja prelazi 99% kod lokalizovane bolesti, ali pada ispod 30% kada se bolest raširi na udaljene organe. Ova razlika motiviše razvoj pouzdanih automatskih sistema za dijagnostičku podršku.

Dermoskopija je neinvazivna tehnika mikroskopije kože koja predstavlja zlatni standard u kliničkoj dermatološkoj praksi. Međutim, tačnost dijagnoze na osnovu dermoskopskih snimaka u velikoj meri zavisi od iskustva dermatologa, zbog čega se javlja potreba za istraživanjima u oblasti automatske klasifikacije. Ranija istraživanja su pokazala da duboke konvolutivne neuronske mreže (eng. *convolutional neural networks*, CNN) u ovom zadatku mogu da se takmiče sa iskusnim dermatolozima [2]. Međutim, automatska klasifikacija u praksi donosi i određene izazove kao što su: ekstreman disbalans klasa, heterogenost izvora i česte artefakte kao što su dlake.

U ovom radu je rešavam problem binarne klasifikacije melanoma (benigno vs. maligno) na *ISIC Challenge 2020* skupu podataka [3], koji sadrži 33.126 dermoskopskih snimaka uz odnos klasa od približno 1:56. Glavni doprinosi rada su:

(1) poređenje dve arhitekture neuronskih mreža u identičnom eksperimentalnom okviru,
(2) arhitektura kasne fuzije (eng. *late fusion*) koja kombinuje vizuelne odlike iz *CNN*-a sa metapodacima pacijenta i *Hu* momentima oblika lezije,
(3) rešavanje disbalansa klasa primenom *Focal Loss* funkcije [4] i *StratifiedGroupKFold* podele po pacijentima koja sprečava curenje podataka (eng. *data leakage*),
(4) proširena evaluacija koja uključuje analizu pravičnosti [5] i kvalitativnu analizu grešaka.

Ostatak rada je organizovan na sledeći način. U poglavlju II dat je kratak pregled relevantne literature. U poglavlju III je opisan skup podataka i rezultate eksplorativne analize. Poglavlje IV predstavlja primenjene metode, dok poglavlje V prikazuje eksperimentalnu proceduru i rezultate. Poglavlje VI donosi analizu pravičnosti, a zaključak i pravci budućeg rada dati su u poglavlju VII.

II. Pregled relevantne literature

Automatska klasifikacija melanoma dubokim neuronskim mrežama je aktivna oblast istraživanja već više od decenije. Prvu prelomnu tačku donela je studija [2] u kojoj je *GoogLeNet Inception v3*, treniran na 129.450 kliničkih slika, dostigao nivo 21 certifikovanog dermatologa. Taj rad je pokazao da *transfer learning* pristup, fino podešavanje mreža pretreniranih na *ImageNet*-u na medicinski skup, može da nadoknadi ograničenu veličinu medicinskih skupova podataka, princip koji je u radu korišćen kod *EfficientNet* modela.

Javno dostupni skupovi odigrali su ključnu ulogu u širenju ove oblasti. *HAM10000* skup [6], sa 10.015 slika u sedam kategorija, postao je standard za istraživanja u dermatologiji, dok serija *ISIC* takmičenja donosi veće i raznorodnije skupove. U ovom radu korišćen je *ISIC 2020* skup [3] koji sadrži 33.126 slika od 2.056 pacijenata, za razliku od *HAM10000*, ima binaran cilj i ekstreman disbalans klasa (1,76% malignih primera), što ga čini realističnijim testom za kliničku primenu.

Napredak u samim arhitekturama CNN-a direktno je oblikovao naš izbor modela. Rezidualne veze uvedene u *ResNet*-u [7] rešavaju problem nestajućeg gradijenta i omogućavaju treniranje veoma dubokih mreža, *DenseNet* [8] ide korak dalje time što svakom sloju daje direktan pristup obeležjima svih prethodnih, smanjujući broj parametara uz bolji protok gradijenta, *EfficientNet* [9] spaja skaliranje širine, dubine i rezolucije u jedinstvenu kompozitnu strategiju i postiže najbolje rezultate u odnosu na aktuelne standarde oblasti (eng. *state-of-the-art*) rezultate sa manje parametara. Svaka od ovih arhitektura koristi drugačiji mehanizam za prenos informacija kroz mrežu, pa je njihovo poređenje na istom zadatku jedan od centralnih doprinosa ovog rada.

Specifične izazove medicinskih skupova rešavaju dva pristupa na kojima se rad oslanja. *Focal Loss* [4] je predložen kao modifikacija *cross-entropy* gubitka koja teškim primerima daje veću težinu, što je direktno primenljivo na disbalans u *ISIC* skupu, pa je u svim eksperimentima zamenio standardnu *cross-entropy* funkciju. Za evaluaciju pravičnosti modela po demografskim grupama primenjen je *Equalized Odds* kriterijum [5], koji zahteva jednake stope tačno pozitivnih (eng. *True Positive Rate*, TPR) i lažno pozitivnih (eng. *False Positive Rate*, FPR) predikcija između grupa, i predstavlja jedan od najčešće korišćenih standarda algoritamske pravičnosti u literaturi.

III. Skup podataka i eksplorativna analiza

U ovom poglavlju su opisane osnovne karakteristike *ISIC 2020* skupa, distribucija klasa i demografskih atributa, kao i zaključci eksplorativne analize koji su motivisali izbor koraka preprocesiranja.

A. Karakteristike ISIC 2020 skupa

ISIC 2020 skup sadrži 33.126 dermoskopskih snimaka visoke rezolucije od 2.056 pacijenata. Svaki uzorak uključuje: JPG sliku, jedinstveni identifikator (*image_name*), identifikator pacijenta (*patient_id*), pol, približnu starost u godinama, anatomsku lokaciju lezije, tip dijagnoze i binarnu oznaku *target* koji može biti 0 ili 1 (0 = benigno, 1 = maligno).

B. Distribucija klasa

Skup je ekstremno neubalansiran: 32.542 benigne (98,24%) i svega 584 maligne lezije (1,76%), što daje odnos približno 1:56. Ovaj disbalans direktno utiče na izbor metrika i loss funkcije (videti poglavlje IV).

C. Demografska analiza

Eksplorativna analiza pokazuje da je distribucija polova približno izbalansirana (52% muških, 48% ženskih pacijenata), dok je starosna distribucija koncentrisana u opsegu 40-70 godina. Za 65 pacijenata nedostaje podatak o polu ili starosti, i ovi slučajevi se tretiraju posebnom '*unknown*' kategorijom umesto uklanjanja. Dominantne anatomske lokacije su torzo (50,9%), donji ekstremiteti (18,6%) i gornji ekstremiteti (14,2%).

D. Uklanjanje dlaka - preprocesiranje

Dermoskopski snimci često sadrže dlake koje mogu dovesti do pogrešne klasifikacije. Primenjena je morfološka *Black-Hat* transformacija za detekciju tamnih linearnih struktura na svetloj koži, nakon čega je korišćen *Telea inpainting* algoritam [10] za popunjavanje detektovanih regiona. Pregledom rezultata uočeno je da postupak uspešno uklanja dlake, a da sama lezija ostaje netaknuta.

E. Hu momenti

Hu momenti [11] su sedam invarijantnih momenata koji opisuju oblik binarne slike i rotacijski, skalarno i translacijski su invarijantni. Izračunavamo prva četiri Hu momenta nakon binarizacije lezije, primenjujemo logaritamsku transformaciju ($\text{sign}(m)\cdot\log|m|$) zbog numeričke stabilnosti, i koristimo ih kao dodatna obeležja u vektoru metapodataka.

IV. Metod

U ovom poglavlju opisan je pristup rešavanju problema, od izbora arhitektura i procedure kasne fuzije, preko izbora *loss* funkcije i *cross-validacione* šeme, do tehničkih rešenja koja su omogućila izvođenje eksperimenata na ograničenim računarskim resursima.

A. Arhitekture modela

U radu su poređene dve arhitekture konvolutivnih neuronskih mreža, jedna trenirana od nule, kao *baseline*, i jedna zasnovana na *transfer learning* pristupu. Oba modela su trenirana po istoj proceduri kako bi poređenje bilo objektivno.

1. *Baseline Custom CNN*: Tri konvolutivna bloka (32, 64, 128 filtera) sa *Batch Normalization* i *Max Pooling* slojevima, praćena globalnim prosečnim *pooling*-om i potpuno povezanim slojevima. Ulazna slika je dimenzije 128×128. Model je treniran od nule (eng. *from scratch*) i služi kao *baseline* sa kojim se upoređuje naprednija arhitektura.
2. *EfficientNet B0* [9]: *Pretreniran* na *ImageNet*-u, koristi *MBConv* blokove sa *depthwise separable* konvolucijama i *Squeeze-and-Excitation* mehanizmom. Izlaz *backbone*-a je 1280-dimenzioni vektor. Ulazna slika je 224×224.

B. Kasna fuzija sa metapodacima

Za oba modela primenjena je identična struktura završnih slojeva koji obavljaju klasifikaciju. Vektor vizuelnih obeležja iz *backbone*-a konkateniše se sa 14-dimenzionim vektorom metapodataka (pol, starost, anatomska lokacija, Hu momenti). Dobijeni vektor prolazi kroz potpuno povezan sloj sa 256 neurona, *ReLU* aktivaciju i *Dropout* sa verovatnoćom 0,3, a završni sloj sadrži jedan neuron sa *sigmoid* aktivacijom na izlazu. Ovakav pristup se naziva kasna fuzija (eng. *late fusion*), jer se različiti izvori informacija spajaju tek pri kraju mreže, nakon što su obeležja iz svakog izdvojena zasebno.

C. Focal Loss za disbalans klasa

Standardna binarna cross-entropy funkcija nije pogodna za skupove sa ekstremnim disbalansom jer dominantna klasa potiskuje gradijent manjinske. Iz tog razloga primenjen je *Focal Loss* [4] sa parametrima α=0,25 i γ=2,0:

$$FL(p_t) = -\alpha(1 - p_t)^{\gamma} \log(p_t)$$

gde p_t označava verovatnoću tačne klase, α balansira težinu klasa, a γ kontroliše smanjenje gubitka za dobro klasifikovane primere. Pri vrednosti γ = 2 primer sa p_t = 0,9 doprinosi gubitku oko 100 puta manje od primera sa p_t = 0,1, čime se proces učenja usmerava na teške, pogrešno klasifikovane uzorke.

D. Podela podataka i cross-validacija

Za evaluaciju je primenjena 5-*fold StratifiedGroupKFold* podela koja istovremeno obavlja dve funkcije:

1. stratifikacija po ciljnoj varijabli *target*, održavajući odnos klasa u svakom foldu
2. grupisanje po identifikatoru pacijenta *patient_id*, sprečavajući da se slike istog pacijenta pojave u train i validation skupu istovremeno

Ovo je ključno za sprečavanje curenja podataka, jer pacijenti često imaju više snimaka sličnih lezija pa bi standardna *random* podela precenila performanse modela.

E. Optimizacija i treniranje

Za optimizaciju parametara izabran je *Adam* optimizator sa početnom stopom učenja 1×10^{-4}, veličinom *batch*-a 32 i ukupno 15 epoha po *fold*-u. Dinamika stope učenja je regulisana pomoću *ReduceLROnPlateau scheduler* (faktor smanjenja 0,5 i strpljenje od 3 epohe bez poboljšanja), a treniranje je prekidano ranije pomoću mehanizma *early stopping* zasnovanog na validacionom AUC-ROC skoru (strpljenje 5 epoha). Na trening skup primenjena je augmentacija podataka u vidu horizontalnog i vertikalnog preokretanja, rotacija do 45°, kao i varijacija osvetljenja i kontrasta, dok validacioni skup nije menjan. Za stabilnije treniranje pretreniranih modela korišćena je *ImageNet* normalizacija sa vrednostima srednje vrednosti [0,485; 0,456; 0,406] i standardne devijacije [0,229; 0,224; 0,225].

V. Rezultati i diskusija

U ovom poglavlju prikazani su rezultati eksperimentalne evaluacije oba modela, kao i uporedna analiza njihovih performansi na skupu podataka *ISIC 2020*.

A. Eksperimentalna procedura

Svi eksperimenti izvedeni su na *Google Colab* platformi uz *Tesla T4* GPU. Za svaki od dva modela sprovedena je 5-*fold* unakrsna validacija, što ukupno daje 10 nezavisnih procedura treniranja. Iz svakog *fold*-a su sačuvane *out-of-fold* (*OOF*) predikcije, koje su zatim objedinjene i korišćene za izračunavanje agregatnih metrika na nivou celog skupa podataka.

B. *Metrike evaluacije*

Zbog ekstremnog disbalansa klasa, accuracy nije adekvatna metrika, trivijalan klasifikator koji uvek predviđa benigno bi imao 98,24% tačnost. Umesto toga koristimo:

1. AUC-ROC - površina ispod ROC krive, glavna metrika nezavisna od praga
2. PR-AUC - površina ispod Precision-Recall krive, osetljivija na performanse manjinske klase
3. Odziv (eng. *Recall*) - ključna u medicinskom kontekstu jer minimizuje lažno negativne rezultate (propuštene melanome)
4. Preciznost, F1 i Macro F1.

Pored standardnog praga 0,5, rezultati su prikazani i na optimalnom pragu određenom *Youden*-ovim J indeksom (J = TPR - FPR, gde TPR označava stopu tačno pozitivnih, a FPR stopu lažno pozitivnih).

C. *Glavni rezultati*

Tabela I. Poređenje modela (OOF rezultati, 5-fold CV)

Metrika	Custom CNN	EfficientNet B0
AUC-ROC	0,821	0,885
PR-AUC	0,067	0,168
Odziv	0,853	0,856
F1	0,086	0,115

Tabela I prikazuje glavne metrike za *Custom CNN* i *EfficientNet B0* modele. *EfficientNet B0* postiže *AUC-ROC* od 0,885, što predstavlja poboljšanje od 6,4% u odnosu na *baseline* CNN (0,821). *PR-AUC* je gotovo dvostruko veći kod *EfficientNet*-a (0,168 vs. 0,067), što ukazuje na značajno bolju sposobnost modela da u svojim predikcijama istakne maligne uzorke iznad benignih.

Niske apsolutne vrednosti PR-AUC su očekivana posledica ekstremnog disbalansa - bazni PR nivo za slučajan klasifikator je samo 0,0176. U tom kontekstu, PR-AUC od 0,168 (EfficientNet) predstavlja 9,5 puta poboljšanje nad *random baseline*-om.

D. *ROC krive i poređenje foldova*

Na slici 1 prikazane su ROC krive oba modela. *EfficientNet* zasnovan na prenesenom učenju dominira nad osnovnim *CNN*-om u gotovo celom opsegu FPR vrednosti, što se manifestuje kao veća površina ispod krive i povoljniji odnos TPR/FPR pri niskim pragovima. Varijansa performansi između *fold*-ova je umereno niska (standardna devijacija ≤ 0,021), što ukazuje na stabilnost procesa treniranja i konzistentnost modela na različitim podelama podataka.

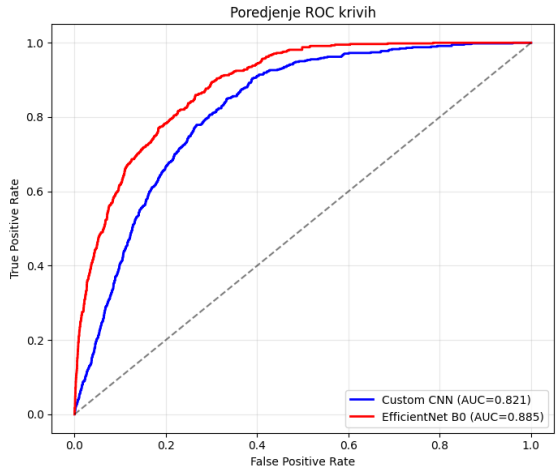

Slika 1. ROC krive poređenih modela sa OOF predikcijama. Siva dijagonala predstavlja random klasifikator.

E. *Matrica konfuzije na optimalnom pragu*

Na optimalnom pragu određenom *Youden*-ovim J indeksom, *EfficientNet B0* je ostvario 502 tačno pozitivne (TP) i 82 lažno negativne predikcije (FN), kao i 25.058 tačno negativnih (TN) uz 7.484 lažno pozitivnih (FP) (Slika 2). U kontekstu kliničkog *screening*-a, ovakav rezultat znači da model uspešno detektuje približno 86% malignih slučajeva uz stopu od oko 23% benignih uzoraka koji se upućuju na dodatnu inspekciju, što predstavlja operativno prihvatljiv kompromis između senzitivnosti i opterećenja zdravstvenog sistema.

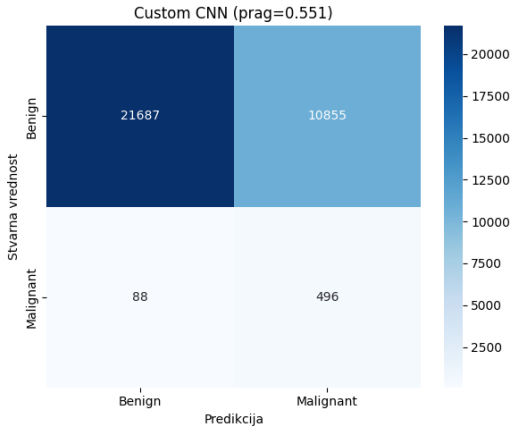

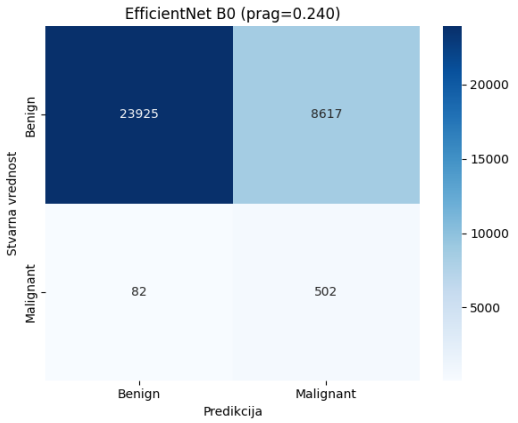

Slika 2. Matrice konfuzije za Custom CNN i EfficientNet B0 na optimalnom pragu po Youden-ovom J indeksu.

F. *Kvalitativna analiza grešaka*

Pregledom pogrešno klasifikovanih uzoraka na validacionom skupu uočeno je nekoliko tipičnih obrazaca u greškama modela. Lažno negativne predikcije, iako manje brojne, najčešće su se javljale kod malignih lezija čiji izgled u velikoj meri podseća na bezopasne promene na koži, što njihovo razlikovanje čini izazovnim čak i za iskusne dermatologe. Lažno pozitivne predikcije su se, sa druge strane, dominantno odnosile na bezopasne ali vizuelno atipične lezije koje pokazuju asimetriju, neravnomerne ivice i nejednaku obojenost, što i jesu karakteristike koje model ispravno prepoznaje kao sumnjive, ali koje same po sebi nisu dovoljne za postavljanje definitivne dijagnoze.

Ovakvo ponašanje modela konzistentno je sa *ABCD* pravilom (eng. *Asymmetry, Border, Color, Diameter*) koje dermatolozi koriste u kliničkoj praksi prilikom inicijalne procene sumnjivih lezija, što sugeriše da model implicitno uči klinički relevantne vizuelne obrasce, ali i da se suočava sa istim granicama razlikovanja koje postoje i u stručnoj procenjivačkoj praksi.

VI. Analiza pravičnosti

Pravednost (eng. *fairness*) algoritamskih sistema predstavlja kritičan faktor u medicinskom kontekstu - model koji sistematski pokazuje slabije performanse nad određenom demografskom grupom može dodatno produbiti postojeće zdravstvene nejednakosti. U okviru ovog rada primenjen je kriterijum izjednačenih šansi (eng. *Equalized Odds*) [5], koji zahteva približnu jednakost stopa tačno pozitivnih (TPR) i lažno pozitivnih (FPR) predikcija među grupama definisanim osetljivim atributima.

A. *Disparitet po polu*

Za EfficientNet B0 model na optimalnom pragu, TPR kod muških pacijenata iznosi 0,87, dok je kod ženskih 0,83, što daje disparitet od 0,04. Disparitet u FPR vrednostima još je manji i iznosi 0,02. Ovako umerene razlike su u skladu sa prethodno objavljenim nalazima u literaturi, melanom je statistički češći kod muškaraca, što se odražava i u korišćenom skupu podataka (52% naspram 48%), pa model tokom treniranja ima na raspolaganju veći broj pozitivnih primera u ovoj grupi.

B. *Disparitet po starosnoj grupi*

Pacijenti su grupisani u tri starosne kategorije:

- mladi (<40 godina),
- srednjih godina (40-70 godina) i
- stariji (>70 godina)

Najveći disparitet uočen je kod mladih pacijenata, za koje TPR iznosi 0,76 u poređenju sa 0,87 u srednjoj grupi (disparitet 0,11). Najverovatniji uzrok leži u ograničenoj zastupljenosti malignih slučajeva u mladoj populaciji unutar trening skupa, što model dovodi u situaciju da ima manje mogućnosti da nauči specifičnosti lezija karakteristične za tu podgrupu.

C. *Implikacije i ograničenja*

Iako uočeni dispariteti nisu izraženi do nivoa koji bi se mogao oceniti kao alarmantan, rezultati sugerišu da bi eventualna klinička primena zahtevala dodatne intervencije, poput prilagođavanja pragova odlučivanja po demografskim grupama ili uvođenja tehnika *oversampling*-a manje zastupljenih podgrupa tokom treniranja. Dodatno ograničenje predstavlja sam sastav skupa *ISIC 2020*, koji pretežno obuhvata pacijente svetlijih tipova kože (*Fitzpatrick* tipovi I-II), što značajno ograničava generalizaciju modela na tamnije tipove kože - faktor koji se mora eksplicitno uzeti u obzir prilikom svake primene sistema u realnom kliničkom okruženju.

VII. Proširenje: Poređenje dubokih neuronskih mreža

U prethodnim poglavljima predstavljene su dve arhitekture (prilagođena konvolutivna mreža i EfficientNet B0) i osnovni *pipeline*. Da bismo ispitali kako različite arhitekture utiču na kvalitet klasifikacije, eksperiment je proširen sa još dve duboke mreže - ResNet-50 i DenseNet-121. Ove dve arhitekture predstavljaju dva važna pravca u razvoju konvolucionih mreža: rezidualne veze i guste veze. Time je omogućeno ujednačeno poređenje četiri modela pod istom strategijom treniranja, istom funkcijom gubitka i istim protokolom evaluacije. Fokus ovog proširenja je

razumevanje zašto različite arhitekturalne odluke daju slične ili drugačije rezultate, kako se ponaša dinamika njihovog treniranja i kakav je doprinos prenesenog učenja u svakoj varijanti.

A. *ResNet-50 i rezidualne veze*

ResNet arhitektura [7] uvela je rezidualne blokove sa prečicom (eng. *skip connection*) koja omogućava protok gradijenata kroz desetine slojeva bez prigušivanja. Formalno, izlaz rezidualnog bloka zapisuje se kao $H(x) = F(x) + x$, gde $F(x)$ predstavlja naučeni ostatak, a x ulaz bloka. Umesto da svaki blok uči kompletnu transformaciju, on uči samo korekciju u odnosu na identitet. Takva formulacija značajno olakšava optimizaciju veoma dubokih mreža i predstavlja jednu od najuticajnijih ideja u oblasti dubokog učenja.

ResNet-50 organizovan je u četiri faze sa 3, 4, 6 i 3 rezidualna bloka, uz primenu *bottleneck* blokova sa 1×1, 3×3 i 1×1 konvolucijama koji smanjuju broj parametara pri zadržavanju izražajnosti. Ukupan broj parametara iznosi približno 25,5 miliona. Za potrebe klasifikacije melanoma, originalni 1000-dimenzionalni klasifikacioni sloj zamenjen je identitetom, a izlaz globalnog prosečnog agregiranja (dimenzije 2048) spojen je sa tabelarnim vektorom metapodataka kroz istu šemu kasne fuzije. Težine su inicijalizovane *ImageNet* pretreniranjem i fino podešavane kroz celu mrežu istom stopom učenja kao kod *EfficientNet*-a.

B. *DenseNet-121 i guste veze*

DenseNet [8] dalje proširuje ideju prečica: svaki sloj prima konkatenirane mape obeležja iz svih prethodnih slojeva unutar iste faze. Takav način povezivanja podstiče ponovnu upotrebu obeležja (eng. *feature reuse*) - svaki naredni sloj ima direktan pristup svim ranijim reprezentacijama, čime se smanjuje potreba da se iste informacije kopiraju kroz mrežu. Posledica je znatno manji broj parametara u odnosu na *ResNet* slične dubine, uz zadržanu ili bolju tačnost.

DenseNet-121 se sastoji od četiri guste faze sa 6, 12, 24 i 16 slojeva, povezane prelaznim blokovima koji kroz 1×1 konvoluciju i prosečno agregiranje smanjuju dimenzionalnost između faza. Stopa rasta (eng. *growth rate*) je 32, što znači da svaki sloj dodaje 32 nove mape obeležja. Ukupno model sadrži oko 8 miliona parametara - približno tri puta manje od *ResNet-50* - što ga čini memorijski efikasnijim pri sličnim performansama. Finalni vektor obeležja dimenzije 1024 spojen je sa metapodacima kroz istu šemu kasne fuzije.

C. *Ujednačeni protokol treniranja*

Radi obezbeđivanja reprezentativnog poređenja, sve četiri arhitekture trenirane su pod identičnim uslovima: Adam optimizator sa početnom stopom učenja 1×10^{-4} i koeficijentom *weight decay* vrednosti 1×10^{-5}, *focal loss* sa $\alpha=0{,}25$ i $\gamma=2{,}0$, maksimalno 20 epoha uz rano zaustavljanje *patience* 5, te ista 5-*fold StratifiedGroupKFold* podela opisana u poglavlju o metodologiji. Ulazna rezolucija za *ResNet-50* i *DenseNet-121* postavljena je na 224×224, u skladu sa pretreniranim *ImageNet* modelima. Identičan su zadržani i koraci preprocesiranja slika (uklanjanje dlaka, *offline* keširanje u .npy format) i ekstrakcija tabelarnih obeležja.

D. *Uporedni rezultati četiri arhitekture*

Tabela II sumira srednju vrednost AUC-ROC po fold-u za sve četiri arhitekture dobijene 5-*fold* unakrsnom validacijom, dok Slika 3 prikazuje odgovarajuće ROC krive na *out-of-fold* predikcijama. Pretrenirane arhitekture postižu praktično izjednačene performanse (AUC-ROC ≈ 0,889), sa razlikom unutar jedne standardne devijacije, što se vizuelno ogleda u gotovo potpunom preklapanju njihovih ROC krivih. Prilagođena CNN mreža zaostaje oko 5,4 procenata, čime se potvrđuje vrednost prenesenog učenja na medicinskom skupu ograničene veličine.

***Tabela II**. Srednja vrednost AUC-ROC po arhitekturi (5-fold CV).*

Model	Mean AUC	Std	Min fold	Max fold
Prilagođena CNN	0,835	0,017	0,803	0,852
ResNet-50	0,889	0,025	0,847	0,915
DenseNet-121	0,888	0,025	0,852	0,923
EfficientNet B0	0,889	0,021	0,857	0,921

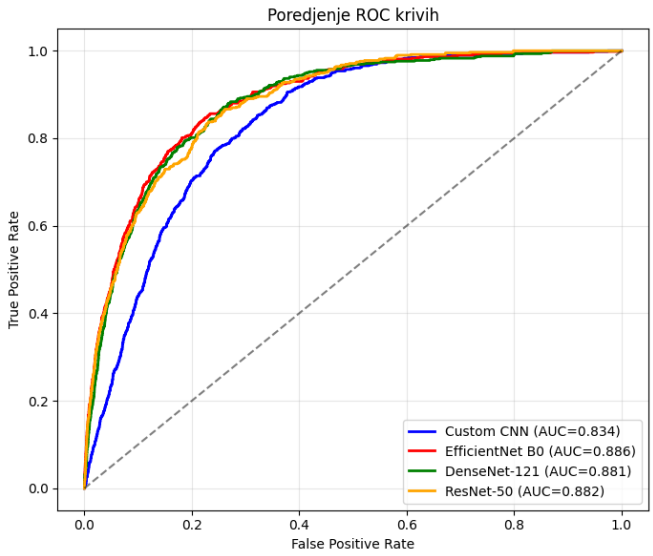

Slika 3. *Poređenje ROC krivih*

Detaljne metrike na optimalnom pragu, izračunate iz predikcija izvan trening fold-a (eng. *out-of-fold, OOF*), date su u Tabeli III.

Model	Prag	Recall	Precision	F1	Macro F1	PR-AUC
CNN	0,404	0,853	0,045	0,086	0,446	0,067
ResNet-50	0,413	0,837	0,061	0,114	0,491	0,153
DenseNet-121	0,449	0,880	0,056	0,105	0,474	0,136
EfficientNet B0	0,322	0,856	0,062	0,115	0,491	0,168

Tabela III. *OOF metrike na optimalnom pragu za sve četiri arhitekture.*

Slika 4 prikazuje matrice konfuzije sve četiri arhitekture na optimalnom pragu odlučivanja. *EfficientNet B0* izdvaja se najvećim PR-AUC-om (0,168), što odražava njegovu sposobnost da zadrži precizan rang čak i za manjinsku klasu u ekstremno neuravnoteženom skupu. *DenseNet-121* postiže najviši *Recall* pri podrazumevanom pragu 0,5 i istovremeno ima optimalni prag najbliži vrednosti 0,5, što ukazuje na bolje kalibrisan izlazni prostor verovatnoća. *ResNet-50* ostvaruje najujednačeniji kompromis između osetljivosti i specifičnosti.

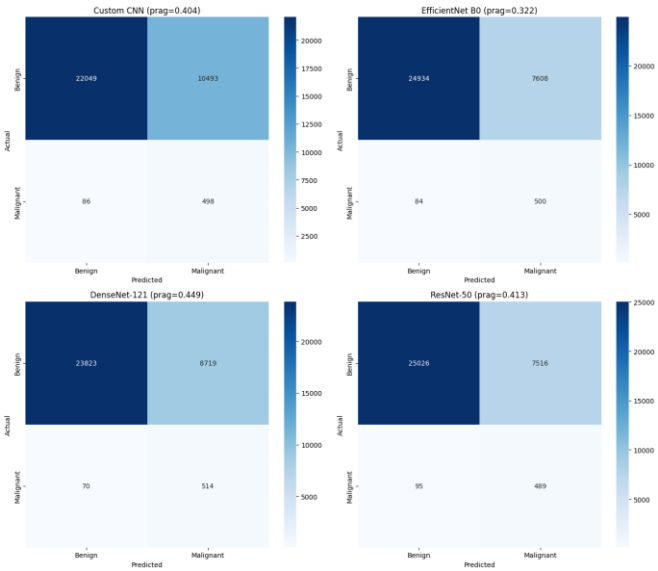

Slika 4. *Matrice konfuzije za sva 4 modela*

E. Dinamika treniranja i regularizacija

Krive gubitka otkrivaju izrazite razlike u brzini konvergencije između arhitektura. Prilagođena mreža, trenirana od nule, pokazuje postepen pad validacionog gubitka i njeno rano zaustavljanje aktivira se u proseku između 16. i 20. epohe. Pretrenirane arhitekture konvergiraju znatno brže: *DenseNet-121* i *EfficientNet B0* dostižu najbolji validacioni AUC između 9. i 15. epohe, dok *ResNet-50* dostiže vrhunac između 11. i 16. epohe. Takvo ponašanje posledica je činjenice da pretrenirana mreža polazi od već uspostavljenih niskonivojskih filtera (ivice, teksture, boje), pa joj nije potrebno više epoha da nauči osnovne vizuelne koncepte - ostaje samo da se fino podese kasniji slojevi za specifičan domen dermoskopskih snimaka.

Kod *DenseNet*-a i *EfficientNet*-a zabeležen je blaži pad validacionog gubitka u kasnijim epohama, što ukazuje na efektivniju regularizaciju - kod *DenseNet*-a kroz ponovnu upotrebu obeležja, a kod *EfficientNet*-a kroz mobilni obrnuti *bottleneck* sa *squeeze-and-excitation* modulima. *ResNet-50* pokazuje nešto izraženiju tendenciju ka preprilagođavanju (eng. *overfitting*) u kasnijim epohama, što je verovatna posledica njegovog velikog kapaciteta (25 miliona parametara) pri istoj stopi učenja kao i kod manjih mreža. Rano zaustavljanje efikasno neutralizuje taj efekat.

F. Diskusija arhitekturalnih izbora

Činjenica da tri pretrenirane arhitekture - uprkos tome što su zasnovane na različitim osnovnim idejama (rezidualne veze, guste veze, složeno skaliranje) - konvergiraju ka praktično istoj performansi ima nekoliko mogućih objašnjenja. Prvo, dominantno ograničenje na ovom skupu je

količina i kvalitet pozitivnih primera, a ne kapacitet mreže. Sa svega 584 maligna slučaja raspoređena po 2.056 pacijenata, mreže različitih kapaciteta dostižu sličan granični nivo onoga što se može naučiti iz dostupnog signala. Drugo, preneseno znanje ujednačuje polazne uslove - sve tri arhitekture počinju od *ImageNet* reprezentacija, pa su niskonivojski filteri unapred stabilizovani i fino podešavanje se odvija samo u kasnijim slojevima. Treće, ekstremna neuravnoteženost klasa postavlja informacionu gornju granicu na performanse, što potvrđuju niske vrednosti PR-AUC-a (0,13 - 0,17) kod svih pretreniranih modela.

Individualne prednosti svake arhitekture ipak se uočavaju. *DenseNet-121* proizvodi najuravnoteženiju distribuciju verovatnoća na izlazu (optimalni prag najbliži 0,5), što se može tumačiti kao posledica ponovne upotrebe obeležja - gusto povezani slojevi integrišu informacije kroz više apstraktnih nivoa istovremeno. *EfficientNet B0*, uprkos najmanjem broju parametara (oko 5,3 miliona), postiže najvišu PR-AUC vrednost, čime se potvrđuje da dobro projektovana arhitektura može nadvisiti veće modele u zavisnosti od zadatka. *ResNet-50* ostvaruje najravnomerniju raspodelu grešaka, bez izražene tendencije ka specifičnosti ili osetljivosti.

Praktična implikacija ovih rezultata je da na skupovima reda desetina hiljada medicinskih snimaka izbor konkretne pretrenirane arhitekture ima manji uticaj od kvaliteta preprocesiranja, pravilne strategije validacije (grupisanje po pacijentu, sprečavanje curenja podataka) i adekvatne funkcije gubitka za neuravnotežen skup podataka.

VIII. Zaključak i budući rad

U radu je predstavljena potpuna obrada (eng. *pipeline*) za binarnu klasifikaciju melanoma na osnovu dermoskopskih snimaka, zasnovana na dubokim konvolutivnim neuronskim mrežama sa kasnom fuzijom metapodataka o pacijentu. Sistematski su upoređene dve arhitekture na skupu *ISIC 2020,* osnovni *CNN* treniran od nule i pretrenirani *EfficientNet B0,* pri čemu je pokazano da pristup zasnovan na prenesenom učenju značajno nadmašuje osnovni model.

Glavni doprinosi rada obuhvataju:

1. kvantitativnu demonstraciju vrednosti prenesenog učenja na medicinskom skupu ograničene veličine, sa poboljšanjem AUC-ROC vrednosti od 6,4% (0,821 naspram 0,885)
2. efikasan sistem *offline* keširanja preprocesiranih slika, koji je skratio vreme treniranja
3. kvantitativnu analizu pravednosti modela koja je identifikovala umerene disparitete po polu i izraženije disparitete u mlađoj starosnoj grupi
4. reproduktivnu i modularnu implementaciju u *PyTorch*-u, koja omogućava jednostavno proširivanje i ponovno pokretanje eksperimenata.

Glavna ograničenja rada obuhvataju:

1. ekstremni disbalans klasa, koji i pored visokog AUC-ROC-a zadržava apsolutnu vrednost PR-AUC-a na niskom nivou
2. odsustvo eksterne validacije na nezavisnom skupu podataka (poput *HAM10000* ili *PH2*)
3. ograničenu zastupljenost tamnijih tipova kože u skupu *ISIC 2020*, što ograničava generalizaciju modela
4. nedostatak eksplicitne interpretacije odluka modela, koja bi se mogla obezbediti primenom tehnika poput *Grad-CAM* vizuelizacija.

Potencijalni pravci daljeg istraživanja obuhvataju ansambliranje četiri pretrenirane arhitekture analizirane u ovom radu radi ublažavanja njihovih različitih profila grešaka, ispitivanje savremenih arhitektura zasnovanih na transformerima (*Vision Transformer, Swin Transformer*), eksternu validaciju na skupovima *ISIC 2019* i *HAM10000*, primenu tehnika interpretabilnosti poput *Grad-CAM* vizuelizacija i prospektivnu kliničku validaciju na nezavisnom dermatološkom skupu.

IX. Literatura

[1] R. L. Siegel, K. D. Miller, and A. Jemal, "Cancer statistics, 2023," CA: A Cancer Journal for Clinicians, vol. 73, no. 1, pp. 17–48, 2023.

[2] A. Esteva et al., "Dermatologist-level classification of skin cancer with deep neural networks," Nature, vol. 542, pp. 115–118, 2017.

[3] V. Rotemberg et al., "A patient-centric dataset of images and metadata for identifying melanomas using clinical context," Scientific Data, vol. 8, p. 34, 2021.

[4] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in Proc. IEEE ICCV, 2017, pp. 2980–2988.

[5] M. Hardt, E. Price, and N. Srebro, "Equality of opportunity in supervised learning," in Proc. NeurIPS, 2016, pp. 3315–3323.

[6] P. Tschandl, C. Rosendahl, and H. Kittler, "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions," Scientific Data, vol. 5, 180161, 2018.

[7] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE CVPR, 2016, pp. 770–778.

[8] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in Proc. IEEE CVPR, 2017, pp. 4700–4708.

[9] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in Proc. ICML, 2019, pp. 6105–6114.

[10] A. Telea, "An image inpainting technique based on the fast marching method," Journal of Graphics Tools, vol. 9, no. 1, pp. 23–34, 2004.

[11] M.-K. Hu, "Visual pattern recognition by moment invariants," IRE Transactions on Information Theory, vol. 8, no. 2, pp. 179–187, 1962.